

1. 《Machine Learning A Probabilistic Perspective》这本书的练习题: Exercise 6.4(10分)
2. Exercise 7.5(20分)
3. Exercise 7.6(20分)
4. Exercise 8.3(15分)
5. Exercise 8.6(25分)
- 6.把Poisson分布写成指数族的形式，并求解其期望和方差。(10分)

1 Ex6.4 解:

由于 $X \sim \mathcal{N}(\mu, \sigma^2)$, 由最大似然的公式:

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

取对数似然函数,

$$\begin{aligned} \ln L(\mu, \sigma) &= \ln(2\pi\sigma^2)^{-\frac{n}{2}} + \ln \exp\left(-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\right) \\ &= -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned}$$

对 σ^2 求偏导,

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \quad \Rightarrow \quad \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

由此可以得到,

$$\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

而

$$E[\hat{\sigma}_{MLE}^2] = E\left[\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2\right] = \sigma^2$$

故给定 μ , 对 σ^2 的最大似然估计是无偏的.

2 Ex7.5 解:

计算负对数似然 NLL:

$$NLL(w, w_0) \propto \sum_{n=1}^N (y_n - w_0 - w^T x_n)^2$$

分别对两个参数求导:

$$\frac{\partial}{\partial w_0} NLL(w, w_0) \propto -Nw_0 + \sum_{n=1}^N (y_n - w^T x_n)$$

$$w_{0,MLE} = \frac{1}{N} \sum_{n=1}^N (y_n - w^T x_n) = \bar{y} - w^T \bar{x}$$

对 X 和 y 分别进行中心化处理:

$$X_c = X - \hat{X}$$

$$y_c = y - \hat{y}$$

此时中心化的数据均值都为 0, 所以此时线性回归模型中没有 w_0 这一项, 同时可得:

$$w_{MLE} = (X_c^T X_c)^{-1} X_c^T y_c$$

3 Ex7.6 解:

由第 3 题可知,

$$X_c = X - \hat{X}, \quad y_c = y - \hat{y}, \quad w_0 = \bar{y} - w^T \bar{x}$$

那么可得

$$\begin{aligned} w_1 &= \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{\sum_i x_i y_i - N\bar{x}\bar{y}}{\sum_i x_i^2 - N\bar{x}^2} \approx \frac{cov[X, Y]}{var[X]} \\ w_0 &= \bar{y} - w_1 \bar{x} \approx E[Y] - w_1 E[X] \end{aligned}$$

4 Ex8.3 解:

$$a) \frac{\partial}{\partial a} \sigma(a) = \frac{\exp(-a)}{(1+\exp(-a))^2} = \frac{1}{1+e^{-a}} \frac{e^{-a}}{1+e^{-a}} = \sigma(a)(1-\sigma(a))$$

b) 由题意,

$$\begin{aligned} g(\mathbf{w}) &= \frac{\partial}{\partial \mathbf{w}} NLL(\mathbf{w}) = \sum_{n=1}^N \frac{\partial}{\partial \mathbf{w}} [y_i \log \mu_i + (1-y_i) \log(1-\mu_i)] \\ &= \sum_{n=1}^N y_i \frac{1}{\sigma} \sigma(1-\sigma) - x_i + (1-y_i) \frac{-1}{1-\sigma} \sigma(1-\sigma) - x_i \\ &= \sum_{n=1}^N (\sigma(\mathbf{w}^T x_i) - y_i) x_i \end{aligned}$$

c) 对于一个任意的 (形状正确的) 非零向量 u :

$$u^T X^T S X u = (X u)^T S (X u)$$

因为 S 为正定矩阵, 所以对于任何形状正确的非零 v :

$$v^T S v > 0$$

因为 X 满秩, 所以 Xu 非零, 所以:

$$(X u)^T S (X u) = u^T (X^T S X) u > 0$$

所以 $X^T S X$ 为正定矩阵.

5 Ex8.6 解:

a) F.

$J(\mathbf{w})$ 的第一项的海森矩阵为正定矩阵, 第二项的海森矩阵仍为正定矩阵 ($\lambda > 0$), 所以这个函数的海森矩阵正定, 故其有全局最优解.

b) F.

考察后验分布的形式:

$$p(\mathbf{w}|D) \propto p(D|\mathbf{w})p(\mathbf{w})$$

$$p(\mathbf{w}) = N(\mathbf{w}|0, \sigma^{-2}I)$$

$$NLL(\mathbf{w}) = -\log p(\mathbf{w}|D) = -\log p(D|\mathbf{w}) + \frac{1}{2\sigma^2} \mathbf{w}^T \mathbf{w} + c$$

所以 $\lambda = \frac{1}{2\sigma^2}$, 全局最优解中零的数量和 λ 的取值有关, λ 值负相关于 \mathbf{w} 的先验不确定性, 其不确定性越小, 则 \mathbf{w} 越趋向于零向量, 所以最后取得的最终解中零也会越多.

c) T.

如果 $\lambda = 0$, 即先验不确定性无穷大, 后验估计变为最大似然估计. 因为此时对于 \mathbf{w} 没有限制, 所以有可能有 \mathbf{w} 的分量趋近于无穷.

d) F.

当 λ 增大时, 意味着先验的不确定性减少, 所以整个模型的过拟合性质被减弱, 一般而言这会导致训练集上的准确率下降.

e) F.

当 λ 增大时, 过拟合性质的减弱一般而言能带来在测试集上的准确率上升, 不过这并不一定发生.

6 解:

泊松分布的形式为

$$p(x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$$

由指数族的定义和标准形式，泊松分布可写成指数族形式

$$p(x|\lambda) = \frac{1}{x!} \exp(x \log \lambda - \lambda)$$

对于 X 服从泊松分布，有

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

$$E(X) = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k e^{-\lambda}}{k!} = \sum_{k=1}^{\infty} \frac{\lambda^k e^{-\lambda}}{(k-1)!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

而

$$\begin{aligned} E(X^2) &= \sum_{k=0}^{\infty} k^2 \cdot \frac{\lambda^k e^{-\lambda}}{k!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{k \lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{(k-1+1) \lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} \left(\sum_{m=0}^{\infty} \frac{m \cdot \lambda^m}{m!} + \sum_{m=0}^{\infty} \frac{\lambda^m}{m!} \right) (\text{令 } m = k-1) \\ &= \lambda e^{-\lambda} \left(\lambda \cdot \sum_{m=1}^{\infty} \frac{\lambda^{m-1}}{(m-1)!} + \sum_{m=0}^{\infty} \frac{\lambda^m}{m!} \right) \\ &= \lambda e^{-\lambda} (\lambda e^{\lambda} + e^{\lambda}) \\ &= \lambda(\lambda + 1) \end{aligned}$$

故有

$$D(X) = E(X^2) - (E(X))^2 = \lambda(\lambda + 1) - \lambda^2 = \lambda$$